

Técnicas de aprendizaje automático en astrofísica. Detección de exoplanetas

Trabajo de Fin de Grado

Autor: Carlos González Marco

Tutor: José Enrique Adsuara Fuster



VNIVERSITAT
DE VALÈNCIA



Escola Tècnica Superior
d'Enginyeria **ETSE-UV**

Grado en Ingeniería Telemática

10 de septiembre de 2019

Índice

1 Introducción

- Planteamiento
- Motivación y objetivos

2 Marco teórico

- Astrofísica y exoplanetas
- Aprendizaje automático

3 Especificación

- Requisitos y especificación
- Análisis de riesgos
- Planificación y estimación

4 Desarrollo del proyecto

- Análisis
- Diseño
- Implementación

5 Pruebas y resultados

- Modelos y rendimiento
- Usabilidad
- Cierre y evaluación

6 Conclusión


- Conclusiones y trabajo futuro

Índice

- 1 **Introducción**
 - Planteamiento
 - Motivación y objetivos
- 2 **Marco teórico**
 - Astrofísica y exoplanetas
 - Aprendizaje automático
- 3 **Especificación**
 - Requisitos y especificación
 - Análisis de riesgos
 - Planificación y estimación

- 4 **Desarrollo del proyecto**
 - Análisis
 - Diseño
 - Implementación
- 5 **Pruebas y resultados**
 - Modelos y rendimiento
 - Usabilidad
 - Cierre y evaluación
- 6 **Conclusión**
 - Conclusiones y trabajo futuro

Planteamiento



Índice

1 Introducción

- Planteamiento
- Motivación y objetivos

2 Marco teórico

- Astrofísica y exoplanetas
- Aprendizaje automático

3 Especificación

- Requisitos y especificación
- Análisis de riesgos
- Planificación y estimación

4 Desarrollo del proyecto

- Análisis
- Diseño
- Implementación

5 Pruebas y resultados

- Modelos y rendimiento
- Usabilidad
- Cierre y evaluación

6 Conclusión

- Conclusiones y trabajo futuro

Motivación y objetivos

Shaulle y Vandenburg (2017)

Detección de exoplanetas con redes neuronales (aprendizaje profundo).
Buenos resultados, pero con un alto coste computacional.

Motivación

Estudiar métodos de aprendizaje automático que puedan ser útiles en el campo de la astrofísica, especialmente en la detección de exoplanetas:

- Regularización de Tíjonov (Regresión de Arista, *Ridge Regression*).
- Proceso de Gauss (*Gaussian Process*).
- Red Neuronal (*Neural Network*).

Objetivos

Introducir teoría, estudiar los algoritmos y sus modelos en Python, implementar un programa y extraer conclusiones.

Índice

- 1 **Introducción**
 - Planteamiento
 - Motivación y objetivos
- 2 **Marco teórico**
 - Astrofísica y exoplanetas
 - Aprendizaje automático
- 3 **Especificación**
 - Requisitos y especificación
 - Análisis de riesgos
 - Planificación y estimación

- 4 **Desarrollo del proyecto**
 - Análisis
 - Diseño
 - Implementación
- 5 **Pruebas y resultados**
 - Modelos y rendimiento
 - Usabilidad
 - Cierre y evaluación
- 6 **Conclusión**
 - Conclusiones y trabajo futuro

Astrofísica y exoplanetas

Astrofísica

Ciencia que estudia los fenómenos físicos que regulan el comportamiento de los objetos astronómicos.

Planetas extrasolares

Cuerpos planetarios que orbitan una o varias estrellas, fuera de nuestro Sistema Solar.


Fotometría de tránsito

Si la órbita de un exoplaneta cruza la trayectoria entre la estrella y el observador (eclipse), se aprecian caídas en la luminosidad: curvas de luz.

Otros de detección de exoplanetas:

- Indirectos: microlente gravitacional, astrometría...
- Directos: observación directa (luz visible o infrarroja).

Fotometría de tránsito



Bases de datos: NASA Exoplanet Archive y MAST

Nasa Exoplanet Archive

Contiene tablas de KOI con metadatos (*KepID*, *disposition...*). Usa una API URL, se puede automatizar la descarga con `urlretrieve`.

Mikulski Archive for Space Telescopes

Almacena datos astronómicos de diferentes misiones. Existe un módulo Python para obtener datos, `astroquery`.

Interrelación entre las BB. DD.

Identifican de forma diferente los KOI:

$$KepID_{NASA} \rightarrow KepID_{MAST} = "kplr0..." + KepID_{NASA}$$


Misión Kepler



Kepler



<http://cdsportal.u-strasbg.fr>



<https://mast.stsci.edu>

Índice

1 Introducción

- Planteamiento
- Motivación y objetivos

2 Marco teórico

- Astrofísica y exoplanetas
- Aprendizaje automático

3 Especificación

- Requisitos y especificación
- Análisis de riesgos
- Planificación y estimación

4 Desarrollo del proyecto

- Análisis
- Diseño
- Implementación

5 Pruebas y resultados

- Modelos y rendimiento
- Usabilidad
- Cierre y evaluación

6 Conclusión

- Conclusiones y trabajo futuro

Aprendizaje automático

Definición

Consiste en programar ordenadores para que adquieran la capacidad de *aprender* de los datos que manejan.

Aprendizaje supervisado

Se mapean las entradas hacia las salidas deseadas. Requiere datos de entrenamiento con los resultados esperados (etiquetas). Ejemplos: procesos de regresión y clasificación.

Regularización de Tíjonov

Incorpora información adicional a un conjunto de datos, para solucionar un problema mal definido o evitar el sobreajuste.

$$A \cdot x = b \longrightarrow \min_{x \in \mathbb{R}^n} \|A \cdot x - b\|^2 + \alpha^2 \cdot \|x\|_2^2, \quad \alpha > 0$$


Aprendizaje automático

Proceso de Gauss

Se basa en funciones de similitud entre puntos (Kernel) para realizar las predicciones, siguiendo una distribución de probabilidad normal. Con la interpolación *kriging* se pueden optimizar los parámetros del Kernel.

Red neuronal (perceptrón multicapa)

Cada neurona clasifica las entradas aplicando una función de activación, que depende de los pesos de cada conexión y de un valor umbral.



$$u_j = \sum_{i=1}^n w_{ij} \cdot x_{ij} - \theta_j$$

$$s_j(u_j) = \begin{cases} 1, & u_j \geq 0 \\ -1, & u_j < 0 \end{cases}$$

Índice

- 1 **Introducción**
 - Planteamiento
 - Motivación y objetivos
- 2 **Marco teórico**
 - Astrofísica y exoplanetas
 - Aprendizaje automático
- 3 **Especificación**
 - Requisitos y especificación
 - Análisis de riesgos
 - Planificación y estimación

- 4 **Desarrollo del proyecto**
 - Análisis
 - Diseño
 - Implementación
- 5 **Pruebas y resultados**
 - Modelos y rendimiento
 - Usabilidad
 - Cierre y evaluación
- 6 **Conclusión**
 - Conclusiones y trabajo futuro

Análisis de requisitos y especificación del sistema

Requisitos

- Funcionales: personalización, ejecución en paralelo, salidas gráficas...
- No funcionales: gestión de errores y avisos, empaquetado de módulos adicionales...

Ciclo de vida

Desarrollo en espiral: combina los desarrollos en cascada y de prototipos.

Clasificación de las funciones

- Módulos generales: comprobación y arranque.
- Módulos de *front-end*: interfaz de usuario.
- Módulos de *back-end*: manejo de ficheros y datos, aprendizaje automático.

Índice

1 Introducción

- Planteamiento
- Motivación y objetivos

2 Marco teórico

- Astrofísica y exoplanetas
- Aprendizaje automático

3 Especificación

- Requisitos y especificación
- **Análisis de riesgos**
- Planificación y estimación

4 Desarrollo del proyecto

- Análisis
- Diseño
- Implementación

5 Pruebas y resultados

- Modelos y rendimiento
- Usabilidad
- Cierre y evaluación

6 Conclusión

- Conclusiones y trabajo futuro

Análisis de riesgos

Riesgos

- ❶ Pérdida de documentación.
- ❷ La aplicación no se ejecuta.
- ❸ Error en lectura/escritura.
- ❹ La aplicación *se cuelga*.
- ❺ Mala estimación temporal.
- ❻ Alcance mal definido.
- ❼ Sin conexión con las BB. DD.

Mitigación

- ❶ Almacenamiento en línea.
- ❷ Requisitos de instalación.
- ❸ Auto-detectar S. O, introducción manual.
- ❹ Programación por hilos.

Contención

- ❺ Margen de 2 semanas.
- ❻ Simplificar análisis.
- ❼ Introducción manual.

Índice

1 Introducción

- Planteamiento
- Motivación y objetivos

2 Marco teórico

- Astrofísica y exoplanetas
- Aprendizaje automático

3 Especificación

- Requisitos y especificación
- Análisis de riesgos
- Planificación y estimación

4 Desarrollo del proyecto

- Análisis
- Diseño
- Implementación

5 Pruebas y resultados

- Modelos y rendimiento
- Usabilidad
- Cierre y evaluación

6 Conclusión

- Conclusiones y trabajo futuro

Planificación y estimación

Estimación temporal

Estado del Arte (220 h), Especificación (75 h), Análisis (70 h), Diseño (70 h), Implementación (280 h), Pruebas (50 h), Documentación (250 h).

Total: 1015 horas

Estimación de costes

Costes directos: 26.197,43 €.

- *Software*: 1759,20 €.
- *Hardware*: 1820,00 €
- *personal*: 22.618,23 €.

Costes indirectos: 2619,74 €
(10 % costes directos).

Coste total: 28.817,17 €

Índice

1 Introducción

- Planteamiento
- Motivación y objetivos

2 Marco teórico

- Astrofísica y exoplanetas
- Aprendizaje automático

3 Especificación

- Requisitos y especificación
- Análisis de riesgos
- Planificación y estimación

4 Desarrollo del proyecto

- Análisis
- Diseño
- Implementación

5 Pruebas y resultados

- Modelos y rendimiento
- Usabilidad
- Cierre y evaluación

6 Conclusión

- Conclusiones y trabajo futuro

Análisis

Actor

Rol que adopta una persona dentro de la aplicación.

- Usuario.

Casos de uso

Describen cómo el actor interactúa con el sistema:


- Seleccionar raíz.
- Limpiar caché.
- Terminar.
- Cambiar vista.
- Seleccionar gráfica
- Seleccionar clasificador
- Descargar KOI.
- Descargar productos.
- Modelar regresores.
- Modelar clasificadores.
- Ejecutar clasificador.
- Abrir doc./info.

Índice



- 1 **Introducción**
 - Planteamiento
 - Motivación y objetivos
- 2 **Marco teórico**
 - Astrofísica y exoplanetas
 - Aprendizaje automático
- 3 **Especificación**
 - Requisitos y especificación
 - Análisis de riesgos
 - Planificación y estimación

- 4 **Desarrollo del proyecto**
 - Análisis
 - **Diseño**
 - Implementación
- 5 **Pruebas y resultados**
 - Modelos y rendimiento
 - Usabilidad
 - Cierre y evaluación
- 6 **Conclusión**
 - Conclusiones y trabajo futuro

Módulos de la aplicación



División y normalización de curvas SLC



Índice

- 1 **Introducción**
 - Planteamiento
 - Motivación y objetivos
- 2 **Marco teórico**
 - Astrofísica y exoplanetas
 - Aprendizaje automático
- 3 **Especificación**
 - Requisitos y especificación
 - Análisis de riesgos
 - Planificación y estimación

- 4 **Desarrollo del proyecto**
 - Análisis
 - Diseño
 - **Implementación**
- 5 **Pruebas y resultados**
 - Modelos y rendimiento
 - Usabilidad
 - Cierre y evaluación
- 6 **Conclusión**
 - Conclusiones y trabajo futuro

Implementación

Abrir vídeo

https://www.youtube.com/watch?v=1CEk1xW_52Y

Módulo de GUI

Tkinter (Tcl/Tk), considerado el estándar de Python.

Módulos de aprendizaje automático

Numpy (manejo de datos), módulos parametrizables scikit-learn:

- KernelRidge*, RidgeClassifierCV.
- GaussianProcessRegressor, GaussianProcessClassifier.
- MLPRegressor*, MLPClassifier*.
- (*) GridSearchCV (para validación cruzada)

Índice

1 Introducción

- Planteamiento
- Motivación y objetivos

2 Marco teórico

- Astrofísica y exoplanetas
- Aprendizaje automático

3 Especificación

- Requisitos y especificación
- Análisis de riesgos
- Planificación y estimación

4 Desarrollo del proyecto

- Análisis
- Diseño
- Implementación

5 Pruebas y resultados

- Modelos y rendimiento
- Usabilidad
- Cierre y evaluación

6 Conclusión


- Conclusiones y trabajo futuro

Modelos y rendimiento

Parámetros

Tabla *Cumulative* → 100 KepID → 316 SLC → 2278 curvas → 226 regresiones → clasificaciones con 25, 50 y 75 % de entrenamiento.

Resultados



Índice

- 1 **Introducción**
 - Planteamiento
 - Motivación y objetivos
- 2 **Marco teórico**
 - Astrofísica y exoplanetas
 - Aprendizaje automático
- 3 **Especificación**
 - Requisitos y especificación
 - Análisis de riesgos
 - Planificación y estimación

- 4 **Desarrollo del proyecto**
 - Análisis
 - Diseño
 - Implementación
- 5 **Pruebas y resultados**
 - Modelos y rendimiento
 - Usabilidad
 - Cierre y evaluación
- 6 **Conclusión**
 - Conclusiones y trabajo futuro

Usabilidad

Test SUS (*System Usability Scale*)

Contiene 10 afirmaciones. El encuestado señala de 1 a 5 su aprobación por ellas, y la nota se calcula con:

$$nota = \sum (impares - 1) + \sum (5 - pares) \quad (1)$$

Resultados

Se encuestó a 10 personas (5 no familiarizadas con la informática).
Resultado: 85 %, excelente.

Índice

- 1 **Introducción**
 - Planteamiento
 - Motivación y objetivos
- 2 **Marco teórico**
 - Astrofísica y exoplanetas
 - Aprendizaje automático
- 3 **Especificación**
 - Requisitos y especificación
 - Análisis de riesgos
 - Planificación y estimación

- 4 **Desarrollo del proyecto**
 - Análisis
 - Diseño
 - Implementación
- 5 **Pruebas y resultados**
 - Modelos y rendimiento
 - Usabilidad
 - Cierre y evaluación
- 6 **Conclusión**
 - Conclusiones y trabajo futuro

Cierre y evaluación

Evaluación temporal

No se excedieron las 1015 horas. **Cierre en julio** (no se estimaron los períodos vacacionales).

Evaluación económica

El proyecto no ha requerido recursos adicionales. No se amortizó ningún gasto (plazos de 6-10 años en *software-hardware*).

Índice

1 Introducción

- Planteamiento
- Motivación y objetivos

2 Marco teórico

- Astrofísica y exoplanetas
- Aprendizaje automático

3 Especificación

- Requisitos y especificación
- Análisis de riesgos
- Planificación y estimación

4 Desarrollo del proyecto

- Análisis
- Diseño
- Implementación

5 Pruebas y resultados

- Modelos y rendimiento
- Usabilidad
- Cierre y evaluación

6 Conclusión

- Conclusiones y trabajo futuro


Conclusiones y trabajo futuro

Conclusiones

Proyecto con resultados satisfactorios: los modelos responden según lo esperado, el sistema es escalable y se abren nuevas vías de investigación.

Propuestas

- 1 Perfeccionar la segmentación de curvas.
- 2 Estudiar otros modelos algorítmicos.
- 3 Mejorar la interfaz, simplificar procesos.
- 4 Implementar técnicas en otros métodos de detección.



Muchas gracias por su atención

¿Alguna cuestión, comentario...?